


מדריך מערכת הסוכנים

מפעילים dynamic workflows בקלוד קוד: מתי זה שווה, ומתי
דווקא לא

מאת גל, מקים vaknin.ai



משימה ענקית היא לא משימה אחת

אני גל, מקים vaknin.ai. כשמבקשים מקלוד קוד משהו גדול, הוא עובד על זה תור אחרי תור, וכל תוצאת ביניים נכנסת לחלון ההקשר שלו עד שהוא נחנק. מערכת סוכנים עובד אחרת: קלוד כותב סקריפט שמנהל את הסוכנים, הסקריפט מחזיק את הלולאה ואת תוצאות הביניים, וקלוד מקבל בסוף רק את התשובה. במדריך הזה: מתי זה שווה, איך מפעילים, ואיפה זה שורף לכם כסף בלי תמורה.

הרעיון בשורה אחת

מערכת סוכנים הוא לא עוד סוכן. הוא העברת התוכנית מהראש של קלוד לתוך קוד שאתם יכולים לקרוא, לעצור ולהריץ שוב.

איך משתמשים במדריך

- 1 בחרו משימה אחת שגדולה מכדי לעשות ביד.
- 2 הריצו עליה את 4 השאלות. שלוש "כן" ומעלה = שווה מערכת סוכנים.
- 3 העתיקו את התבנית המתאימה, והריצו קודם על פרוסה קטנה.

היכולת נקראת dynamic workflows, ודורשת Claude Code בגרסה 2.1.154 ומעלה. היא זמינה בכל המנויים בתשלום. במנוי Pro צריך להדליק אותה פעם אחת בשורת Dynamic workflows בתוך config/ לפני השימוש.

4 שאלות לפני שמריצים מערכת סוכנים

שלוש תשובות "כן" ומעלה = שווה מערכת סוכנים. פחות מזה, אתם משלמים על תזמור שלא היה צריך לקרות.

1 גדולה מדי?

המשימה לא נכנסת לשיחה אחת: עשרות קבצים או עשרות מקורות. משימה שסוכן אחד גומר בתור אחד לא צריכה מערכת סוכנים.

2 מתפרקת?

אפשר לחתוך אותה לפריטים עצמאיים שאף אחד מהם לא תלוי בשני. אם כל חלק צריך לחכות לקודם, מערכת סוכנים רק מוסיף המתנה.

3 חוזרת?

אתם תרצו להריץ את זה שוב. הסקריפט נשמר כפקודה משלכם ורץ אותו דבר בכל פעם. משימה חד-פעמית קטנה לא מחזירה את העלות.

4 שווה אימות?

התוצאה חשובה מספיק שתוצא שסוכנים בלתי תלויים ינסו להפריך אותה. זה ההבדל בין תשובה שנשמעת נכון לתשובה שעמדה בביקורת.

המבחן על משימה אמיתית

סריקת אבטחה על כל הראוטים באתר. [גדולה מדי ✓]
כל ראוט נבדק בנפרד, אף אחד לא תלוי בשני. [מתפרקת ✓]
אני ארצה להריץ את זה לפני כל שחרור. [חוזרת ✓]
ממצא שגוי יעלה לי יום עבודה. [שווה אימות ✓]

01 מילה אחת בתוך הבקשה

אתם לא כותבים את הסקריפט. מתארים את המשימה במילים שלכם ומוסיפים לבקשה את המילה `ultracode`, וקלוד כותב את הסקריפט שמנהל את הסוכנים. גם "תריץ את זה כ-workflow" עובד אותו דבר.

שלושה צעדים

מוסיפים את המילה `ultracode` לבקשה, והיא מסומנת על המסך. מאשרים את התוכנית שקלוד מציג, אם מצב ההרשאות שבחרתם בכלל מבקש אישור. הריצה עוברת לרקע, והשיחה נשארת פנויה להמשך עבודה.

- המילה קובעת רק איך קלוד בונה את העבודה. ההרשאות והסנדבוקס נשארים בדיוק כמו בכל פעולה אחרת בסשן.
- פקודת `workflows/` מראה כל פאזה עם מספר הסוכנים, הטוקנים והזמן, ואפשר להיכנס לכל סוכן ולקרוא מה מצא. בתוך התצוגה: `p` משהה, `x` עוצר, `s` שומר את הסקריפט כפקודה משלכם.
- שער האישור תלוי במצב ההרשאות שבחרתם. במצב ששמו `Auto` שואלים אתכם רק בהפעלה הראשונה ואז זוכרים את התשובה, ובמצב `bypass` או בהרצה לא אינטראקטיבית לא שואלים בכלל.

בפועל

יש גם מתג לכל הסשן: `ultracode/effort` גורם לקלוד לבחור בעצמו לבנות ריצה כזאת לכל משימה משמעותית, בלי שתבקשו בכל פעם. דורש גרסה 2.1.203 ומעלה ושורף הרבה יותר טוקנים.

5 טעויות שהורגות מערכת סוכנים

אלה המקרים שבהם תקבלו ריצה שנראית מרשימה, ובפועל עולה לכם הרבה ומחזירה מעט.

❌ לשלוח מערכת סוכנים למשימה שסוכן אחד גומר בתור אחד.

ריצה אחת צורכת הרבה יותר טוקנים מאותה משימה בשיחה רגילה. אם זה נכנס בתור אחד, שיירוך בתור אחד.

❌ לתכנן לאשר משהו באמצע הריצה.

אין קלט משתמש באמצע. צריך אישור בין שלבים? הריצו כל שלב כריצה נפרדת.

❌ לשכוח שהסוכנים עורכים קבצים בעצמם.

הסוכנים רצים תמיד ב-acceptEdits ועריכות קבצים מאושרות אוטומטית, בלי קשר למצב ההרשאות שלכם. תריצו על ענף.

❌ לעצור ריצה באמצע פאן-אאוט גדול.

בהמשכה, כל סוכן שהתחיל אחרי זה שלא סיים ירוץ שוב, גם אם הוא כבר סיים. הרבה סוכנים קטנים שומרים יותר התקדמות מסוכן אחד ארוך.

❌ להריץ בפעם הראשונה על כל הריפו.

תריצו על פרוסה: תיקייה אחת במקום הכל. תראו את העלות האמיתית ב-workflows/, ורק אז תרחיבו.

המספרים שכדאי להכיר

מערכת סוכנים הוא הכלי היקר בארגז. אלה הגבולות שהמערכת אונכפת, ומה שאתם יכולים לכוון בעצמכם.

1 16 בו-זמנית

זו התקרה של סוכנים שרצים באותו רגע, ופחות מזה כשיש למחשב שלכם פחות ליבות. אפשר לשלוח מאה פריטים לעיבוד, אבל רק 16 יעבדו בכל רגע נתון.

2 1,000 בריצה

זו התקרה הכוללת של סוכנים בריצה אחת. היא לא יעד, היא בלם נגד סקריפט שנתקע בלולאה.

3 פחות מ-15

זו ברירת המחדל של גודל המערכת. אפשר לשנות אותה בשורת `Dynamic workflow size` ב-`config/`: קטן הוא פחות מ-5 סוכנים, גדול הוא פחות מ-50. דורש גרסה 2.1.219 ומעלה.

4 25 ומעלה

מעל 25 סוכנים, או כשההערכה עוברת 1.5 מיליון טוקנים, מופיעה אזהרת `Large workflow`. היא רק מסמנת ולא עוצרת, ומפנה אתכם ל-`workflows/` כדי לעצור אם בא לכם.

מה עושים בפועל

מריצים על תיקייה אחת לפני שמריצים על הכל.
בודקים איזה מודל דלוק ב-`model/` לפני ריצה גדולה.
פותרים `workflows/` באמצע ורואים כמה טוקנים נשרפו עד כה.

02 ריצה אחת, מהתחלה ועד הדוח

הדרך הכי מהירה לראות מערכת סוכנים עובדת היא לא לכתוב כלום. עם קלוד קוד מגיעה תבנית מובנית בשם deep-research, והיא רצה כמו כל ריצה אחרת: מתפרשת לכיוונים, מצליבה, ומחזירה דוח אחד עם מקורות.

שלושה צעדים

כותבים /deep-research/ ואחריו שאלה שבאמת מעניינת אתכם. מאשרים, והריצה עוברת לרקע. אתם ממשיכים לעבוד באותה שיחה. כותבים /workflows/, בוחרים את הריצה ולוחצים אנטר כדי לראות אותה עובדת.

- בתצוגה רואים כל פאזה עם מספר הסוכנים, הטוקנים והזמן. אפשר להיכנס לסוכן בודד ולקרוא מה קיבל, מה הפעיל ומה החזיר.
- הסוכנים מפוצלים לזוויות חיפוש שונות, ואז שלב נוסף מצליב את המקורות ומצביע על כל טענה. טענה שלא שרדה מסוננת מהדוח לפני שהוא מגיע אליכם.
- טענה שהמאמרים לא הצליחו לבדוק מופיעה כלא-מאומתת ולא נספרת כהופרכה. זה ההבדל בין דוח שאפשר לסמוך עליו לרשימת ניחושים.

בפועל

מה שנוחת בסוף זה דוח אחד עם מקור לכל טענה, ולא תמלול של עשרות תורות. תוצאות הביניים חיו בסקריפט, וחלון ההקשר קיבל רק את השורה התחתונה.

03 סקירת קוד רב-סוכנית

יש לכם הרבה קבצים שצריך לבדוק על אותו דבר, ואתם לא רוצים ממצאים שנשמעים נכון אבל אינם. סוכן נפרד סורק כל קובץ, ואז סוכנים בלתי תלויים מנסים להפריך כל ממצא לפני שהוא מגיע אליכם.

להעתיקה

ultracode: תסרוק כל קובץ ראוט בפרויקט ותחפש בדיקות הרשאה חסרות.

כל ממצא צריך לעבור אימות נגדי של סוכן נפרד שמנסה להפריך אותו. תחזיר רק את מה ששרד, מדורג מהחמור לקל, עם קובץ ושורה.

- הפירוק לפי קובץ נותן לכל סוכן הקשר קטן וממוקד, ולכן הוא רואה דברים שסוכן אחד שקורא הכל מפספס.
- האימות הנגדי הוא מה שמפריד בין תשובה משכנעת לתשובה נכונה. סוכן שמתבקש להפריך מוצא את מה שסוכן שמתבקש לאשר מחמיץ.
- בקשת קובץ ושורה בפלט הופכת את הדוח למשהו שאפשר לפעול לפיו במקום רשימת חששות.
- בפעם הראשונה הריצו על תיקייה אחת. תראו את העלות בתצוגת /workflows, ורק אחר כך תפתחו לכל הפרויקט.

בפועל

אותה תבנית עובדת גם על סקירת שינויים לפני מיזוג: מחליפים "כל קובץ ראוט" ב"כל קובץ שהשתנה", ומוסיפים בקשה לאחד את הממצאים לסיכום מדורג אחד.

04 מיגרציה רוחבית

אותו שינוי צריך לקרות בעשרות או מאות מקומות. זה המקרה שבו מערכת סוכנים באמת חוסך שעות, כי כל פריט עובר את כל השלבים בעצמו בלי לחכות לאחרים.

להעתיקה

ultracode: תמצא את כל המקומות בפרויקט שצריך להעביר לשיטה החדשה.

תעביר כל אחד בעותק מבודד משלו, כדי שהעריכות לא יתנגשו. אחרי כל העברה תריץ בדיקה, ותדווח לי מה עבר ומה נכשל.

- העבודה בעותק מבודד לכל פריט היא מה שמאפשר לסוכנים לערוך במקביל בלי לדרוס אחד את השני.
- אימות מיד אחרי כל שינוי, ולא בסוף, אומר שכישלון בפריט אחד לא מזהם את כל השאר.
- השלב הראשון של גילוי המקומות הוא גם מה שנותן לכם את המספר האמיתי לפני שמתחייבים.
- בקשו מקלוד קודם רק את שלב הגילוי, בלי לשנות כלום. אם המספר שחוזר מפתיע אתכם, עדיף לגלות את זה לפני 200 עריכות.

בפועל

עובד גם על משימות שהן לא קוד: לעבור על כל קובץ תוכן ולתקן בו אותו דפוס, או לעדכן אותו שדה בהמון רשומות.

05 פאנל שופטים להחלטה

החלטה שקשה לחזור ממנה, ואתם לא רוצים להתאהב בגישה הראשונה שעלתה לכם לראש. כמה סוכנים מציעים כיוונים שונים, שופטים בלתי תלויים מנקדים, וסוכן אחרון מסנתז מהמנצחת.

להעתיקה

ultracode: תכתוב לי שלוש גישות שונות לפתרון, כל אחת מזווית אחרת.

אחר כך תן לשופטים בלתי תלויים לנקד כל גישה מול אותם קריטריונים.

תסכם מהמנצחת, ותגיד לי מה שווה לקחת מהאחרות.

- כשכל גישה נכתבת בנפרד ובלי לראות את האחרות, אתם מקבלים מרחב אמיתי במקום שלוש וריאציות על אותו רעיון.
- שיפוט נפרד מהכתיבה מונע מהסוכן להצדיק את מה שהוא עצמו הציע.
- הבקשה למה שווה לקחת מהאחרות היא מה שמונע לזרוק רעיון טוב רק כי הוא הגיע בחבילה שהפסידה.
- תנו לשופטים קריטריונים שאתם באמת מודדים לפיהם. "הכי טוב" נותן שיפוט מעורפל, "הכי מהיר ליישום" נותן הכרעה.

בפועל

מתאים גם להחלטות שאינן טכניות: שלוש דרכים לבנות מבנה מחירים, שלוש זוויות לקמפיין, שלוש דרכים לפרק פרויקט לשלבים.

תריצו אחת, על פרוסה קטנה

אל תחכו למשימה המושלמת. קחו את התבנית שגרמה לכם להנהן, צמצמו אותה לתיקייה אחת או לשאלה אחת, והריצו. אחרי הריצה הראשונה תדעו בדיוק כמה זה עולה לכם, ואז ההחלטה להרחיב היא כבר החלטה מבוססת ולא הימור.

**המשימה שאתם הכי דוחים בגלל
הגודל שלה היא המועמדת הכי טובה.**

עוד מדריכים וכלים מעשיים, כל שבוע ב-vaknin.ai. עקבו כדי לא לפספס את הבא.

גל · vaknin.ai

